

Vectorización, la familia apply y otros

Subconjuntos de diferentes estructuras de datos

Esta sección está basada en Wickham (2014, Subsetting) disponible en [línea](#).

Aprender a extraer subconjuntos de los datos es importante y permite realizar operaciones complejas con los mismos. De los conceptos importantes que se deben aprender son

- Los operadores para extraer subconjuntos (subsetting operators)
- Los 6 tipos de extracciones de subconjuntos
- Las diferencias a la hora de extraer subconjuntos de las diferentes estructuras de datos (factores, listas, matrices, dataframes)
- El uso de la extracción de subconjuntos junto a asignar variables.

Cuando tenemos que extraer pedazos de los datos (o analizar solamente parte de éstos), necesitamos complementar `str()` con `[[`, es decir, la estructura nos dirá cómo utilizar el operador subconjunto de manera que de hecho extraigamos lo que queremos. `##` Operadores para extraer subconjuntos

Dependiendo la estructura de datos que tenemos, será la forma en la que extraemos elementos de ella. Hay dos operadores de subconjunto: `[[` y `$`. `[[` se parece a `[` pero regresa un solo valor y te permite sacar pedazos de una lista. `$` es un atajo útil para `[[`. `###` Vectores atómicos

¿De qué formas puedo extraer elementos de un vector? Hay varias maneras **sin importar** la *clase* del vector.

- **Enteros positivos** regresan los elementos en las posiciones especificadas en el orden que especificamos.

```
x <- c(5.6, 7.8, 4.5, 3.3)
```

```
x[c(3, 1)]
```

```
## [1] 4.5 5.6
```

```
## Si duplicamos posiciones, nos regresa resultados duplicados
```

```
x[c(1, 1, 1)]
```

```
## [1] 5.6 5.6 5.6
```

```
## Si usamos valores reales, se coercion a entero
```

```
x[c(1.1, 2.4)]
```

```
## [1] 5.6 7.8
```

```
x[order(x)]
```

```
## [1] 3.3 4.5 5.6 7.8
```

```
x[order(x, decreasing = T)]
```

```
## [1] 7.8 5.6 4.5 3.3
```

- **Enteros negativos** omiten los valores en las posiciones que se especifican.

```
x
```

```
## [1] 5.6 7.8 4.5 3.3
```

```
x[-c(3, 1)]
```

```
## [1] 7.8 3.3
```

Mezclar no funciona.

```
x[c(-3, 1)]
```

- **Vectores lógicos** selecciona los elementos cuyo valor correspondiente es **TRUE**. Esta es una de los tipos más útiles.

```
x[c(TRUE, TRUE, FALSE, FALSE)]
```

```
## [1] 5.6 7.8
```

```
x[c(TRUE, FALSE)] # Autocompleta el vector lógico al tamaño de x
```

```
## [1] 5.6 4.5
```

```
x[c(TRUE, TRUE, NA, FALSE)]
```

```
## [1] 5.6 7.8 NA
```

- **Nada** si no especifico nada, me regresa el vector original

```
x[]
```

```
## [1] 5.6 7.8 4.5 3.3
```

- **Cero** el índice cero no aplica en R, te regresa el vector vacío

```
x[0]
```

```
## numeric(0)
```

- Si el vector tiene **nombres** también los puedo usar.

```
names(x) <- c("a", "ab", "b", "c")
x["ab"]
```

```
## ab
## 7.8
```

```
x["d"]
```

```
## <NA>
## NA
```

```
x[grep("a", names(x))]
```

```
## a ab
## 5.6 7.8
```

Las **listas** operan básicamente igual a vectores recordando que si usamos `[` regresa una lista y tanto `[[` y `$` extrae componentes de la lista. `###` Matrices y arreglos

Para estructuras de mayor dimensión se pueden extraer de tres maneras:

- Con vectores múltiples
- Con un solo vector
- Con una matriz

```
m <- matrix(1:12, nrow = 3)
colnames(m) <- LETTERS[1:4]
m[1:2, ]
```

```
##      A B C D
## [1,] 1 4 7 10
## [2,] 2 5 8 11
```

```
m[c(T, F, F), c("B", "C")]
```

```
## B C
## 4 7
```

```
m[1, 4]
```

```
## D
## 10
```

Como ven, es solamente generalizar lo que se hace en vectores replicándolo al número de dimensiones que se tiene.

```
m[c(T, F, F)]
```

```
## [1] 1 4 7 10
```

```
class(m[c(T, F, F)])
```

```
## [1] "integer"
```

[simplifica al objeto. En matriz, me quita la dimensionalidad, en listas me da lo que esta dentro de esa celda.

Dataframes

```
df <- data.frame(x = 1:3, y = 3:1, z = letters[1:3])
```

```
df[c(1, 2), ]
```

```
##   x y z
## 1 1 3 a
## 2 2 2 b
```

```
df[, c(1, 2)]
```

```
##   x y
## 1 1 3
## 2 2 2
## 3 3 1
```

```
df[, c("z", "x")]
```

```
##   z x
## 1 a 1
## 2 b 2
## 3 c 3
```

```
df[c("z", "x")]
```

```
##   z x
## 1 a 1
## 2 b 2
## 3 c 3
```

```
class(df[, c("z", "x")])
```

```
## [1] "data.frame"
```

```
class(df[c("z", "x")])
```

```
## [1] "data.frame"
```

```
str(df["x"])
```

```
## 'data.frame':   3 obs. of  1 variable:
## $ x: int  1 2 3
```

```
str(df[, "x"])
```

```
## int [1:3] 1 2 3
```

```
str(df$x)
```

```
## int [1:3] 1 2 3
```



Ejercicios

1. Utiliza la base mtcars
2. Arregla los errores al extraer subconjuntos en dataframes

```
mtcars[mtcars$cyl == 4, ]  
mtcars[-1:4, ]  
mtcars[mtcars$cyl <= 5]  
mtcars[mtcars$cyl == 4 | 6, ]
```

3. ¿Por qué al correr `x <- 1:5; x[NA]` obtengo valores perdidos?
4. Genera una matriz cuadrada tamaño 5 llamada m. ¿Qué te da correr `m[upper.tri(m)]`?
5. ¿Por qué al realizar `mtcars[1:20]` me da un error? ¿Por qué `mtcars[1:2]` no me lo da? ¿Por qué `mtcars[1:20,]` es distinto?
6. Haz una función que extraiga la diagonal de la matriz m que creaste antes. Debe dar el mismo resultado que ejecutar `diag(m)`
7. ¿Qué hace `df[is.na(df)] <- 0`?

Asignar a un subconjunto

Muchas veces lo que necesitamos es encontrar ciertos valores para poder reemplazarlos con algo más. Por ejemplo, muchas veces queremos imputar valores perdidos con cierto valor.

```
# Variables continuas  
x <- c(1, 2, 3, NA, NaN, 7)  
media <- mean(x, na.rm = T)  
media
```

```
## [1] 3.25
```

```
x[is.na(x)] <- media  
x
```

```
## [1] 1.00 2.00 3.00 3.25 3.25 7.00
```

```
# Variables discretas  
x <- c(rep("azul", 3), "verde", NA, "verde", rep("rojo", 4))  
x
```

```
## [1] "azul" "azul" "azul" "verde" NA "verde" "rojo" "rojo"
## [9] "rojo" "rojo"
```

```
moda <- names(table(x))[which(table(x) == max(table(x)))] # Engorroso, no?
x[is.na(x)] <- moda
x
```

```
## [1] "azul" "azul" "azul" "verde" "rojo" "verde" "rojo" "rojo"
## [9] "rojo" "rojo"
```

```
# Puedo reemplazar partes de un vector
x <- 1:5
x[c(1, 2)] <- 2:3
x
```

```
## [1] 2 3 3 4 5
```

```
# Las longitudes de las asignaciones tienen que ser iguales
x[-1] <- 4:1
x
```

```
## [1] 2 4 3 2 1
```

```
# No se revisan duplicados
x[c(1, 1)] <- 2:3
x
```

```
## [1] 3 4 3 2 1
```

```
# Puedo sustituir valores considerando toda la logica
x <- c(1:10)
x[x > 5] <- 0
x
```

```
## [1] 1 2 3 4 5 0 0 0 0 0
```

Por último, es útil notar la utilidad de asignar utilizando la forma de asignar **nada** mencionada anteriormente.

```
class(mtcars)
```

```
## [1] "data.frame"
```

```
mtcars[] <- lapply(mtcars, as.integer)
class(mtcars)
```

```
## [1] "data.frame"
```

```
dim(mtcars)
```

```
## [1] 32 11
```

```
mtcars <- lapply(mtcars, as.integer)  
class(mtcars)
```

```
## [1] "list"
```

```
dim(mtcars)
```

```
## NULL
```

Asignar utilizando el operador de suconjunto a nada nos permite preservar la estructura del objeto original así como su clase.

En el caso de listas, si combinamos un operador de suconjunto mas asignación a nulo, podemos remover objetos de ésta.

```
x <- list(a = 1, b = 2)  
x[[2]] <- NULL  
str(x)
```

```
## List of 1  
## $ a: num 1
```

```
x["b"] <- list(NULL)  
str(x)
```

```
## List of 2  
## $ a: num 1  
## $ b: NULL
```

Operadores lógicos

Operador	Descripción
<	menor que
<=	menor o igual que
>	mayor que
==	exactamente igual que
!=	diferente de
!x	no x
x y	x O y
x & y	x Y y
isTRUE(x)	checa si x es verdadero

Ejemplo: Supongamos que queremos saber qué elementos de x son menores que 5 y mayores que 8.

```
x <- c(1:10)
x[(x>8) | (x<5)]
```

```
## [1] 1 2 3 4 9 10
```

```
# ¿Cómo funciona?
x
```

```
## [1] 1 2 3 4 5 6 7 8 9 10
```

```
x > 8
```

```
## [1] FALSE FALSE FALSE FALSE FALSE FALSE FALSE TRUE TRUE
```

```
x < 5
```

```
## [1] TRUE TRUE TRUE TRUE FALSE FALSE FALSE FALSE FALSE
```

```
x > 8 | x < 5
```

```
## [1] TRUE TRUE TRUE TRUE FALSE FALSE FALSE TRUE TRUE
```

```
# x > 8 || x < 5
x[c(T,T,T,T,F,F,F,T,T)]
```

```
## [1] 1 2 3 4 9 10
```

|| vs. | y && vs. &

La diferencia entre & y && (o | y ||) es que el primero es vectorizado y el segundo no.

Ejercicio ¿Qué crees que pasa en las siguientes situaciones?

```
rm(list = ls())
TRUE || a
FALSE && a
TRUE && a
TRUE | a
FALSE & a
```

La forma larga (la versión doble) no parece ser muy útil. El propósito de ésta es que es más apropiado cuando se programa usando estructuras de control, por ejemplo, en **ifs**.

```
if( c(T, F) ) print("Hola")
```

```
## Warning in if (c(T, F)) print("Hola"): the condition has length > 1 and
## only the first element will be used
```

```
## [1] "Hola"
```

Poner el && me garantiza que la condicional será evaluado sobre un único valor falso/verdadero.


```
(-2:2) >= 0
```

```
## [1] FALSE FALSE TRUE TRUE TRUE
```

```
(-2:2) <= 0
```

```
## [1] TRUE TRUE TRUE FALSE FALSE
```

```
((-2:2) >= 0) && ((-2:2) <= 0)
```

```
## [1] FALSE
```

Ejercicio Explora los siguientes comandos

```
impares <- 1:10 %% 2 == 1  
mult.3 <- 1:10 %% 3 == 0
```

```
impares & mult.3  
impares | mult.3
```

```
xor(impares, mult.3)
```

¿Por qué tanto detalle? Aplicaciones

Una de las formas más fáciles de frustrarse con R (y con cualquier otro lenguaje) es no saber decirle al lenguaje lo que se desea hacer. Entender cómo manipular las estructuras de datos y la lógica detrás de su comportamiento ahorra mucho sufrimiento y permite adaptarse ante cosas que necesitamos que aún no se encuentran implementadas por alguien más de una manera más sencilla.

Con saber de subconjuntos podemos realizar varias tareas indispensables. `##` Buscarv o buscarh

Excel es excelente haciendo estas tareas. Lo malo de excel es que no es **reproducible**. Es muy común que resulte imposible llegar de los datos originales al resultado final pues muchos pasos intermedios de limpieza no están documentados de forma alguna. Un *script* de limpieza nos permite no solamente ir del *raw* a la estructura de datos limpia y analizable sino que permite que alguien más verifique las operaciones que se están realizando, se identifiquen errores y que, cuando nos llega un nuevo mes, sea trivial incluir estos datos al resultado final.

```
rm(list = ls())  
x <- c("m", "f", "u", "f", "f", "m", "m")  
busca <- c(m = "Male", f = "Female", u = NA)  
busca[x]
```

```
##           m           f           u           f           f           m           m  
##  "Male" "Female"      NA "Female" "Female"  "Male"  "Male"
```

```
unname(busca[x])
```

```
## [1] "Male"  "Female" NA      "Female" "Female" "Male"  "Male"
```

```
c(m = "humano", f = "humano", u = "desconocido")[x]
```

```
##           m           f           u           f           f
##    "humano"    "humano" "desconocido"    "humano"    "humano"
##           m           m
##    "humano"    "humano"
```

Esto nos permite pegar un vector a una base de datos de acuerdo a una condicion.

```
calificaciones <- c(10, 9, 5, 5, 6)
aprueba <- data.frame(
  calificacion = 10:1,
  descripcion = c(rep("excelente", 2), "bueno", rep("aceptable", 2), rep("no satisfactorio", 5)),
  aprobatorio = c(rep(T, 5), rep(F, 5))
)
id <- match(calificaciones, aprueba$calificacion)
aprueba[id, ]
```

```
##    calificacion    descripcion aprobatorio
## 1             10      excelente         TRUE
## 2              9      excelente         TRUE
## 6              5 no satisfactorio        FALSE
## 6.1            5 no satisfactorio        FALSE
## 5              6      aceptable          TRUE
```



Ejercicios

1. Realiza la misma operación con las calificaciones pero utilizando los nombres de las filas, es decir, los `rownames(aprueba)`
2. Carga la libreria `ggplot2` y utiliza la base de datos `diamonds`
3. Utiliza el comando `match` para quedarte con las variables `cut` y `x`
4. Genera la variable categórica tal que, si el precio es mayor que 5,000 el valor de `price.cat` es cara, si es mayor que 2,000 es normal y barata en otro caso.

Muestras aleatorias

Podemos utilizar índices enteros para generar muestras aleatorias de nuestras bases de datos o de nuestros vectores.

```
set.seed(102030)
aprueba[sample(nrow(aprueba)), ]
```

```
##    calificacion    descripcion aprobatorio
## 10             1 no satisfactorio        FALSE
## 2              9      excelente         TRUE
## 8              3 no satisfactorio        FALSE
## 7              4 no satisfactorio        FALSE
```

```
## 9          2 no satisfactorio      FALSE
## 3          8          bueno        TRUE
## 1         10         excelente     TRUE
## 6          5 no satisfactorio      FALSE
## 4          7          aceptable     TRUE
## 5          6          aceptable     TRUE
```

```
aprueba[sample(nrow(aprueba), replace = T, size = 5), ]
```

```
##      calificacion      descripcion aprobatorio
## 4          7          aceptable      TRUE
## 1         10         excelente      TRUE
## 4.1        7          aceptable      TRUE
## 7          4 no satisfactorio      FALSE
## 2          9         excelente      TRUE
```



Ejercicios

1. Utiliza la base de datos de iris y genera un conjunto de prueba y uno de entrenamiento correspondientes al 20 y 80 % de los datos, respectivamente.
2. Genera un vector x de tamaño 1000 con realizaciones de una normal media 10, varianza 3.
3. Crea 100 muestras bootstrap del vector x.
4. Calcula la media para cada una de tus muestras.
5. Grafica con la función hist() el vector de medias de tus muestras.
6. Genera un vector l de letras, tamaño 10 y ordénalo. (Usa letters y order).
7. Ordena la base cars de acuerdo a distancia, en forma descendiente (muestra la cola -usa tail- de la base ordenada).

Expande bases

Ahora, a veces tenemos tablas de resumen pero quisieramos extraer los datos originales. Combinamos rep con subconjuntos de enteros para expandir.

```
df <- data.frame(
  color = c("azul", "verde", "amarillo"),
  n = c(4, 3, 5)
)
df
```

```
##      color n
## 1     azul 4
## 2     verde 3
## 3 amarillo 5
```

```
df[rep(1:nrow(df), df$n), ]
```

```
##      color n
## 1      azul 4
## 1.1    azul 4
## 1.2    azul 4
## 1.3    azul 4
## 2      verde 3
## 2.1    verde 3
## 2.2    verde 3
## 3  amarillo 5
## 3.1 amarillo 5
## 3.2 amarillo 5
## 3.3 amarillo 5
## 3.4 amarillo 5
```

Otras

Ya estuvimos utilizando otras aplicaciones de estos comandos: ordenamientos, selección de filas o columnas según una condición lógica.

También utilizamos un comando muy útil llamado `which`.

```
set.seed(45)
x <- sample(letters, 10)
x <= "e"
```

```
## [1] FALSE FALSE FALSE FALSE FALSE FALSE TRUE FALSE TRUE TRUE
```

```
which(x <= "e")
```

```
## [1] 7 9 10
```

Junto con `which`, puedes usar `intersect` y `union`.

```
pares <- 1:10 %% 2 == 0
m.5 <- 1:10 %% 5 == 0

c(1:10)[union(which(pares), which(m.5))]
c(1:10)[intersect(which(pares), which(m.5))]
c(1:10)[which(xor(pares, m.5))]
```

Split-apply-combine

El paradigma split-apply-combine se resume en la figura 1.

Entendamos mejor:

```
letras <- sample(letters, 3)
df <- data.frame(
  letra = letras[rep(seq(letras), 4)],
  valor = sample(1:10, size = 12, replace = T)
)
df <- df[order(df$letra), ]
df
```

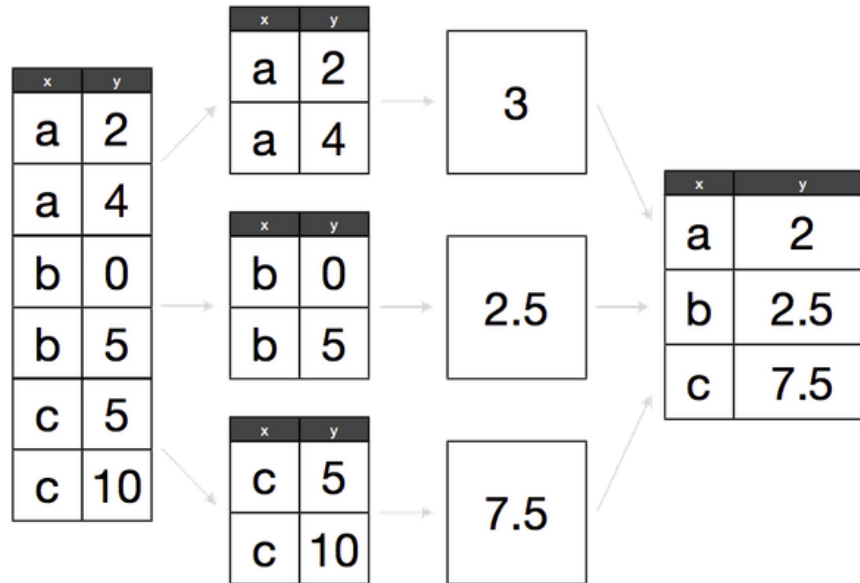


Figura 1: Ejemplificación del split-apply-combine Vaidyanathan (2014, Split-Apply-Combine).

```
##      letra valor
## 3      h      5
## 6      h      5
## 9      h      4
## 12     h      9
## 1      j      5
## 4      j     10
## 7      j      3
## 10     j      6
## 2      w      5
## 5      w      2
## 8      w      2
## 11     w      7
```

Queremos estimar la media del valor para cada tipo de letra.

```
# Dividimos
for (l in unique(df$letra) ){
  print(df[l == df$letra, ])
}
```

```
##      letra valor
## 3      h      5
## 6      h      5
## 9      h      4
## 12     h      9
##      letra valor
## 1      j      5
## 4      j     10
## 7      j      3
## 10     j      6
```

```
##      letra valor
## 2      w      5
## 5      w      2
## 8      w      2
## 11     w      7
```

```
# Aplicamos
for (l in unique(df$letra) ){
  print(mean(df[l == df$letra, ]$valor))
}
```

```
## [1] 5.75
## [1] 6
## [1] 4
```

```
# Combinamos
medias <- list()
for (l in unique(df$letra) ){
  medias[[l]] <- mean(df[l == df$letra, ]$valor)
}
as.data.frame(list(letras = names(medias), medias = unname(unlist(medias))))
```

```
##      letras medias
## 1      h    5.75
## 2      j    6.00
## 3      w    4.00
```

R tiene muchas funciones que facilitan realizar este tipo de operaciones. En particular, la familia `apply` fue pensada para realizar ese tipo de operaciones.

apply

`apply` aplica una función a cada fila o columna en una matriz.

```
m <- matrix(c(1:5, 6:10), nrow = 5, ncol = 2)
# 1 is the row index 2 is the column index
m
```

```
##      [,1] [,2]
## [1,]    1    6
## [2,]    2    7
## [3,]    3    8
## [4,]    4    9
## [5,]    5   10
```

```
apply(m, 1, sum)
```

```
## [1]  7  9 11 13 15
```

```
apply(m, 2, sum)
```

```
## [1] 15 40
```

Ejercicio Haz una función que reciba un vector y devuelva la suma de la posición $v_i + v_{i+1}$. Para el n-esimo elemento, suma el primero. Aplica esa función a las columnas y filas de la matriz m.

lapply

lapply aplica una función a cada elemento en una lista. Como sabemos, un `data.frame` es únicamente un estilo particular de lista tal que todos sus elementos tienen el mismo tamaño. Por ende, también podemos utilizar `lapply` para iterar sobre las columnas de un `data.frame`.

```
lista <- list(a = 1:10, b = 2:20)
lapply(lista, mean)
```

```
## $a
## [1] 5.5
##
## $b
## [1] 11
```

```
df <- data.frame(a = 1:10, b = 11:20)
lapply(df, mean)
```

```
## $a
## [1] 5.5
##
## $b
## [1] 15.5
```

El `summary` de un `data.frame` genera un resumen para los vectores que la conforman de acuerdo a la clase de la misma. Genera una función que regrese una tabla de frecuencias para factores y caracteres o una lista con media, desviación estándar para vectores numéricos o enteros. Aplícalo a la base `diamonds` usando `lapply`.

sapply

`sapply` es otra versión de `lapply` que regresa una lista de una matriz cuando es apropiado.

```
x <- sapply(lista, mean, simplify = F)
x
```

```
## $a
## [1] 5.5
##
## $b
## [1] 11
```

```
x <- sapply(lista, mean, simplify = T)
x
```

```
##      a      b
##  5.5 11.0
```

Ejercicio Obtén un vector tipo caracter con los nombres de las clases de las columnas de iris.

Ejercicio Repite el ejercicio de la suma rara pero usa `sapply`.

Recuerda la instrucción: Haz una función que reciba un vector y devuelva la suma de la posición $v_i + v_{i+1}$. Para el n -esimo elemento, suma el primero. Utiliza `sapply` para realizar esta operacion.

mapply

`mapply` es como la versión multivariada de `sapply`. Le aplica una función a todos los elementos correspondientes de un argumento.

```
l1 <-list(a = c(1:5), b = c(6:10))
l2 <- list(c = c(11:15), d = c(16:20))
l1
```

```
## $a
## [1] 1 2 3 4 5
##
## $b
## [1] 6 7 8 9 10
```

```
l2
```

```
## $c
## [1] 11 12 13 14 15
##
## $d
## [1] 16 17 18 19 20
```

```
mapply(sum, l1$a, l1$b, l2$c, l2$d)
```

```
## [1] 34 38 42 46 50
```

```
l1[["a"]][1] + l1[["b"]][1] + l2[["c"]][1] + l2[["d"]][1]
```

```
## [1] 34
```

tapply

`tapply` le aplica una función a subconjuntos de un vector.


```
head(warpbreaks)
```

```
##   breaks wool tension
## 1     26    A       L
## 2     30    A       L
## 3     54    A       L
## 4     25    A       L
## 5     70    A       L
## 6     52    A       L
```

```
with(warpbreaks, tapply(breaks, list(wool, tension), mean))
```

```
##           L           M           H
## A 44.55556 24.00000 24.55556
## B 28.22222 28.77778 18.77778
```

```
tapply(warpbreaks$breaks,
       list(wool = warpbreaks$wool, tension = warpbreaks$tension),
       mean)
```

```
##      tension
## wool      L      M      H
##   A 44.55556 24.00000 24.55556
##   B 28.22222 28.77778 18.77778
```

Ejercicio

by

by le aplica una función a subconjuntos de un `data.frame`. Se divide un `data.frame` según los valores de de uno o más factores. Se aplica la función FUN a cada subconjunto.

```
head(iris)
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1           5.1           3.5           1.4           0.2  setosa
## 2           4.9           3.0           1.4           0.2  setosa
## 3           4.7           3.2           1.3           0.2  setosa
## 4           4.6           3.1           1.5           0.2  setosa
## 5           5.0           3.6           1.4           0.2  setosa
## 6           5.4           3.9           1.7           0.4  setosa
```

```
by(data = iris[, 1:2], INDICES = iris[, "Species"], FUN = summary)
```

```
## iris[, "Species"]: setosa
##   Sepal.Length   Sepal.Width
##  Min.   :4.300   Min.   :2.300
## 1st Qu.:4.800   1st Qu.:3.200
##  Median :5.000   Median :3.400
```

```
## Mean :5.006 Mean :3.428
## 3rd Qu.:5.200 3rd Qu.:3.675
## Max. :5.800 Max. :4.400
## -----
## iris[, "Species"]: versicolor
## Sepal.Length Sepal.Width
## Min. :4.900 Min. :2.000
## 1st Qu.:5.600 1st Qu.:2.525
## Median :5.900 Median :2.800
## Mean :5.936 Mean :2.770
## 3rd Qu.:6.300 3rd Qu.:3.000
## Max. :7.000 Max. :3.400
## -----
## iris[, "Species"]: virginica
## Sepal.Length Sepal.Width
## Min. :4.900 Min. :2.200
## 1st Qu.:6.225 1st Qu.:2.800
## Median :6.500 Median :3.000
## Mean :6.588 Mean :2.974
## 3rd Qu.:6.900 3rd Qu.:3.175
## Max. :7.900 Max. :3.800
```

Puedo calcular, por ejemplo, la suma de los valores del largo y ancho de los sépalos en la base de datos iris según la especie.

```
res <- by(iris[, c("Sepal.Length", "Sepal.Width")], iris[, "Species"], sum)
```

Posteriormente, se pueden combinar los elementos.

```
as.data.frame(list(
  "species" = names(res),
  "suma" = sapply(seq(length(res)), FUN = function(i) res[[i]])
))
```

```
##      species suma
## 1      setosa 421.7
## 2 versicolor 435.3
## 3 virginica 478.1
```

Ejercicio Vuelve a utilizar la base de diamonds para calcular el promedio de carat según cut y color.

```
##   carat      cut color clarity depth table price      x      y      z
## 1  0.23    Ideal     E    SI2   61.5    55   326  3.95  3.98  2.43
## 2  0.21  Premium     E    SI1   59.8    61   326  3.89  3.84  2.31
## 3  0.23     Good     E    VS1   56.9    65   327  4.05  4.07  2.31
## 4  0.29  Premium     I    VS2   62.4    58   334  4.20  4.23  2.63
## 5  0.31     Good     J    SI2   63.3    58   335  4.34  4.35  2.75
## 6  0.24 Very Good     J   VVS2   62.8    57   336  3.94  3.96  2.48
```

replicate

`replicate` es una función muy útil sobretodo en el contexto de simulación.

```
replicate(5, rnorm(6), simplify = F)
```


```
## [[1]]
## [1] -1.48174362  0.66978164 -0.78426278 -0.45197092  1.02655102  0.02008344
##
## [[2]]
## [1] -0.5126506 -0.4285076  0.5632417  0.1028410  0.1923036  1.1650204
##
## [[3]]
## [1] -0.18038327  0.33794788  0.08232277 -0.10389078 -1.14011737 -0.61650967
##
## [[4]]
## [1]  0.7039886 -2.2066521 -0.8376586  1.7216593  0.4360063  0.7571990
##
## [[5]]
## [1]  1.5398858  1.5393945  2.1829996 -0.9953758 -0.3013422  0.6005107
```

```
replicate(6, rnorm(4), simplify = T)
```

```
##           [,1]      [,2]      [,3]      [,4]      [,5]      [,6]
## [1,] -0.3633049  0.8675148 -1.3168208  1.5543102  0.6130339  0.5737528
## [2,] -0.2211350 -0.1700282 -0.6075526  0.3306465  0.7158021  0.2225771
## [3,] -0.1981113  1.1900491 -0.9454914  0.2031200  0.6501763  1.1414076
## [4,]  0.6676305  0.9188715  1.2493954 -2.5829970  0.7201334 -0.6722725
```

```
hist(replicate(100, mean(rexp(10))))
```

Histogram of replicate(100, mean(rexp(10)))



Ejercicio Replica el ejercicio de muestras bootstrap utilizando replicate.

Recordando:

1. Genera un vector `x` de tamaño 1000 con realizaciones de una normal media 10, varianza 3.
2. Crea 100 muestras bootstrap del vector `x`.
3. Calcula la media para cada una de tus muestras.
4. Grafica con la función `hist()` el vector de medias de tus muestras.

¿Puede ser más fácil?

La familia `apply` viene con R básico. Sin embargo, hay 3 implementaciones excelentes del paradigma split-apply-combine: `plyr`, `dplyr` y `data.table`.

Si la familia `apply` es poderosa, se queda corta comparada con estos tres. `plyr` es la primera versión de s-a-c de Wickham. Posteriormente, mejoró muchas de las funciones en `dplyr` sobretodo entorno a velocidad y facilidad de uso. `plyr` no termina de ser relevante pues varias de sus funciones aun no están en `dplyr`.

`data.table`, es una implementación con una tradición muy diferente y tiene también funciones muy poderosas aunque con una sintaxis muy distinta a `dplyr`. Es absurdamente eficiente y tiene múltiples aplicaciones.

Muchas de las funciones en `dplyr` también están implementadas en `data.table`. Cuál usar es cuestión de gustos. Depende de con qué se acomoda cada quién pero, para algunas cosas uno es superior al otro y viceversa.

Referencias

- [Vai14] Ramnath Vaidyanathan. *Introduction to R*. Github books, en pycon 2014, 2014. URL: <https://ramnathv.github.io/pycon2014-r>.
- [Wic14] Hadley Wickham. *Advanced R*. CRC Press, 2014.

`sessionInfo()`

```
## R version 3.2.2 (2015-08-14)
## Platform: x86_64-pc-linux-gnu (64-bit)
## Running under: Ubuntu 15.04
##
## locale:
##  [1] LC_CTYPE=en_US.UTF-8      LC_NUMERIC=C
##  [3] LC_TIME=es_MX.UTF-8      LC_COLLATE=en_US.UTF-8
##  [5] LC_MONETARY=es_MX.UTF-8  LC_MESSAGES=en_US.UTF-8
##  [7] LC_PAPER=es_MX.UTF-8     LC_NAME=C
##  [9] LC_ADDRESS=C             LC_TELEPHONE=C
## [11] LC_MEASUREMENT=es_MX.UTF-8 LC_IDENTIFICATION=C
##
## attached base packages:
## [1] stats      graphics  grDevices  utils      datasets  base
##
## other attached packages:
## [1] ggplot2_2.0.0  xtable_1.7-4   rformat_0.1    rmarkdown_0.8.1
##
## loaded via a namespace (and not attached):
##  [1] Rcpp_0.12.2.2  digest_0.6.8   plyr_1.8.3     grid_3.2.2
##  [5] gtable_0.1.2   formatR_1.2.1  magrittr_1.5    evaluate_0.8
```

```
## [9] scales_0.3.0      stringi_1.0-1      tools_3.2.2        stringr_1.0.0
## [13] munsell_0.4.2      yaml_2.1.13        colorspace_1.2-6   htmltools_0.2.6
## [17] knitr_1.11         methods_3.2.2
```